

TRƯỜNG ĐẠI HỌC THỦY LỢI



BÁO CÁO BÀI TẬP LỚN

ĐỀ TÀI : NHẬN DẠNG CẢM XÚC TỪ GIỌNG NÓI

Họ Tên	MSV
Nguyễn Đặng Trung Kiên	- 2251262613

Hà nội, 12/2025

MỤC LỤC

1. Giới thiệu (Introduction)	4
1.1 Bối cảnh và Động lực Nghiên cứu	4
1.2 Thách thức Kỹ thuật	5
1.3 Phương pháp Tiếp cận và Đóng góp	6
2. Nghiên cứu liên quan (Related Work)	6
2.1 Thuật toán (Algorithm)	5
Phương pháp Học sâu (Deep Learning):	6
Convolutional Neural Network 2D (CNN 2D)	6
Long Short-Term Memory (LSTM)	7
Mô hình lai CNN-LSTM	8
2.2 Các chỉ số đánh giá (Evaluation metrics)	8
3. Phương pháp luận (Methodology)	9
3.1 Tập dữ liệu (Datasets)	9
3.1.1 Xác định nguồn dữ liệu, tính pháp lý, quyền truy cập:	10
3.1.2 Tự kiểm tra tập dữ liệu gốc trên kaggle	11
3.1.2.1 Tập dữ liệu CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset):	12
3.1.2.2 Tập dữ liệu RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song):	13
3.1.2.3 Tập dữ liệu SAVEE (Surrey Audio-Visual Expressed Emotion):	14
3.1.2.5 Tổng kết	15
3.1.3 Tích hợp và chuẩn hóa dữ liệu:	16
3.1.4 Phân bố lớp cảm xúc	17
3.2. Tiền xử lý và trực quan hóa dữ liệu	18
3.3 Huấn luyện mô hình (Model Training)	19
3.3 Phân tích kết quả và đánh giá (Evaluation & Results Analysis)	20
3.3.1 Phân tích chi tiết từng mô hình	21
CNN 2D	22
LSTM	22
CNN-LSTM (Hybrid Model)	23
3.3.2 Phân tích ma trận nhầm lẫn	24
3.3.3 Phân tích nguyên nhân gốc rễ của sai lệch dự đoán và giới hạn mô hình	24
3.3.3.1 Hiện tượng Quá khớp (Overfitting) nghiêm trọng	25

3.3.3.2 Giới hạn nội tại của phương pháp Mel-Spectrogram kết hợp CNN	26
3.3.3.3 Sự không đồng nhất và mất cân bằng trong dữ liệu đa nguồn	27
4. Một số kịch bản triển khai thêm	27
4.1. Kịch bản cơ sở: Sliding Window	27
4.2. Kịch bản gộp nhãn: Sad-Neutral	28
4.3. Kịch bản gộp nhãn: Sad-Neutral và Fear-Surprise	29
4.4. Kịch bản gộp nhãn: Sad-Neutral, Fear-Surprise và Angry-Disgust	30
4.5. Kịch bản tối ưu: Bỏ Happy	32
4.6. Tổng hợp kết quả	33
5. Kết luận và Hướng phát triển (Conclusion & Future Work)	34
5.1 Kết luận	34
5.2 Hướng phát triển	35
Trong tương lai, nghiên cứu có thể được mở rộng theo các hướng sau:	35
Tài liệu tham khảo	35

1. Giới thiệu

1.1 Bối cảnh và Động lực Nghiên cứu

Trong kỷ nguyên số hóa, sự tương tác giữa Người và Máy (Human-Computer Interaction - HCI) đang trải qua một cuộc cách mạng chuyển dịch từ các giao diện dòng lệnh cứng nhắc sang các phương thức giao tiếp tự nhiên, trong đó giọng nói đóng vai trò trung tâm. Tuy nhiên, một hệ thống giao tiếp thực sự thông minh không chỉ cần hiểu nội dung ngữ nghĩa ("Người dùng nói gì?" - Speech to Text) mà còn phải thấu hiểu các tín hiệu cận ngôn ngữ ("Người dùng nói như thế nào?" - Paralinguistics). Những tín hiệu này, bao gồm ngữ điệu, cường độ, nhịp điệu và chất giọng, chứa đựng thông tin quan trọng về trạng thái cảm xúc, thái độ và ý định của người nói.

Lĩnh vực nghiên cứu tập trung vào việc giải mã các tín hiệu này được gọi là Nhận dạng Cảm xúc trong Giọng nói (Speech Emotion Recognition - SER). Tầm quan trọng của SER đang ngày càng được khẳng định qua hàng loạt ứng dụng thực tiễn:

Dịch vụ khách hàng thông minh: Các hệ thống tổng đài có thể tự động giám sát hàng ngàn cuộc gọi, phát hiện ngay lập tức sự giận dữ hoặc thất vọng của khách hàng để điều hướng đến nhân viên hỗ trợ cấp cao, giúp nâng cao chất lượng dịch vụ.

Y tế và Chăm sóc sức khỏe tâm thần: Giọng nói là một chỉ báo sinh học tiềm năng (biomarker). Các hệ thống SER có thể hỗ trợ bác sĩ trong việc chẩn đoán sớm và theo dõi tiến triển của các bệnh lý như trầm cảm, rối loạn lo âu, hoặc bệnh Parkinson thông qua những thay đổi tinh vi trong giọng nói mà tai thường khó phát hiện.

An toàn giao thông: Trong ngành công nghiệp ô tô, các hệ thống giám sát trong khoang lái (In-cabin monitoring) sử dụng SER để phát hiện trạng thái căng

thăng, mệt mỏi hoặc kích động của tài xế, từ đó đưa ra cảnh báo kịp thời nhằm giảm thiểu tai nạn.

1.2 Thách thức Kỹ thuật

Mặc dù có tiềm năng to lớn, việc xây dựng một hệ thống SER chính xác và mạnh mẽ đối mặt với ba rào cản kỹ thuật lớn:

Sự mơ hồ và chủ quan của cảm xúc. Không có một ranh giới vật lý rõ ràng giữa các trạng thái cảm xúc. Về mặt âm học, sự khác biệt giữa "Buồn" (Sad) và "Trung tính" (Neutral), hay giữa "Sợ hãi" (Fear) và "Ngạc nhiên" (Surprise) thường rất nhỏ và phụ thuộc nhiều vào ngữ cảnh. Điều này gây khó khăn cho cả con người chứ không chỉ riêng máy móc trong việc gán nhãn dữ liệu.

Sự biến thiên của người nói (Speaker Variability). Đây là thách thức lớn nhất. Mỗi cá nhân sở hữu một đặc trưng giọng nói (timbre), cao độ nền và cách diễn đạt cảm xúc riêng biệt. Một mô hình học máy nếu không được thiết kế tốt sẽ dễ rơi vào bẫy "học vẹt" (overfitting) đặc điểm giọng nói của từng người thay vì học đặc trưng chung của cảm xúc. Hầu hết các nghiên cứu cơ bản thường mắc sai lầm khi chia tập dữ liệu ngẫu nhiên (trộn lẫn giọng của một người vào cả tập huấn luyện và kiểm tra), tạo ra độ chính xác ảo nhưng thất bại khi áp dụng vào thực tế với người dùng mới.

Sự khan hiếm và phân tán dữ liệu. Các bộ dữ liệu cảm xúc chất lượng cao thường nhỏ, được thu âm trong môi trường phòng thu (acted speech) và thiếu tính đa dạng. Việc huấn luyện trên một bộ dữ liệu đơn lẻ thường dẫn đến khả năng tổng quát hóa kém.

1.3 Phương pháp Tiếp cận và Đóng góp

Để giải quyết các thách thức trên, nhóm chúng em đề xuất một quy trình tiếp cận toàn diện dựa trên Học sâu (Deep Learning). Các đóng góp chính bao gồm:

Tích hợp Đa nguồn Dữ liệu (Multi-Corpus Integration): Xây dựng không gian dữ liệu phong phú từ 4 nguồn uy tín (RAVDESS, CREMA-D, TESS, SAVEE) để mô hình tiếp xúc với nhiều loại giọng và phong cách thu âm khác nhau.

Đánh giá Độc lập Người nói (Speaker-Independent Evaluation): Áp dụng chiến lược chia tập dữ liệu dựa trên **Speaker_ID**. Điều này đảm bảo mô hình được kiểm tra trên những giọng nói hoàn toàn mới, phản ánh trung thực khả năng ứng dụng thực tế.

So sánh Đa mô hình: Thực hiện so sánh đối chứng giữa CNN 2D, CNN-LSTM, LSTM để xác định kiến trúc tối ưu cho bài toán xử lý ảnh phổ Mel-spectrogram.

2. Nghiên cứu liên quan

2.1 Thuật toán

Phương pháp Học sâu (Deep Learning):

CNN (Convolutional Neural Networks): Ban đầu dành cho xử lý ảnh, CNN đã chứng minh hiệu quả vượt trội trong SER khi coi phổ âm thanh (Spectrogram) như một hình ảnh đầu vào để trích xuất các mẫu cục bộ.

RNN/LSTM (Recurrent Neural Networks): Phù hợp để xử lý chuỗi thời gian, nắm bắt sự thay đổi cảm xúc theo thời gian.

Hybrid Models (CNN-LSTM): Kết hợp khả năng trích xuất đặc trưng không gian của CNN và khả năng ghi nhớ chuỗi của LSTM (mô hình này cũng được cài đặt trong bài để so sánh).

Convolutional Neural Network 2D (CNN 2D)

CNN 2D là một trong những kiến trúc học sâu được sử dụng rộng rãi nhất trong nhận diện cảm xúc từ giọng nói hiện đại. Trong cách tiếp cận này, tín hiệu âm thanh được biểu diễn dưới dạng Mel-spectrogram, tương tự như một ảnh hai

chiều với trục thời gian và trục tần số. Các lớp tích chập của CNN có khả năng tự động học các đặc trưng cục bộ như biên phổ, vùng năng lượng cao và các mẫu đặc trưng liên quan đến cảm xúc.

Ưu điểm chính của CNN 2D là khả năng trích xuất đặc trưng không gian hiệu quả mà không cần thiết kế thủ công. Tuy nhiên, CNN 2D chủ yếu tập trung vào các quan hệ cục bộ và không mô hình hóa rõ ràng sự phụ thuộc dài hạn theo thời gian của tín hiệu lời nói.

Long Short-Term Memory (LSTM)

LSTM là một biến thể của mạng nơ-ron hồi quy được thiết kế để giải quyết vấn đề mất dần gradient trong các mạng RNN truyền thống. Với các cổng nhớ và cơ chế điều khiển trạng thái, LSTM có khả năng ghi nhớ thông tin dài hạn và đặc biệt phù hợp với dữ liệu chuỗi thời gian như tín hiệu giọng nói.

Trong bài toán nhận diện cảm xúc, LSTM thường được áp dụng trên chuỗi đặc trưng Mel theo trục thời gian, cho phép mô hình học được sự thay đổi cảm xúc và nhịp điệu trong quá trình phát âm. Tuy nhiên, khi sử dụng đơn lẻ, LSTM có thể gặp khó khăn trong việc học các đặc trưng không gian phức tạp của phổ tần số, đặc biệt khi số lượng đặc trưng đầu vào lớn.

Mô hình lai CNN–LSTM

Mô hình CNN–LSTM kết hợp ưu điểm của cả hai kiến trúc CNN và LSTM, được xem là một trong những phương pháp hiệu quả nhất trong nhận diện cảm xúc từ giọng nói hiện nay. Trong kiến trúc này, CNN đóng vai trò trích xuất các đặc trưng không gian cục bộ từ Mel-spectrogram, trong khi LSTM xử lý chuỗi các đặc trưng này theo thời gian nhằm nắm bắt động học cảm xúc của lời nói.

Sự kết hợp này cho phép mô hình học đồng thời cả cấu trúc phổ và sự biến thiên theo thời gian, từ đó cải thiện đáng kể hiệu năng so với các mô hình đơn lẻ.

CNN–LSTM đặc biệt phù hợp với các tập dữ liệu đa nguồn và đa dạng người nói.

2.2 Các chỉ số đánh giá

Việc đánh giá hệ thống nhận diện cảm xúc từ giọng nói đòi hỏi sử dụng nhiều chỉ số khác nhau nhằm phản ánh đầy đủ hiệu năng của mô hình trong bối cảnh dữ liệu thường không cân bằng.

Độ chính xác (Accuracy) là chỉ số cơ bản, biểu thị tỷ lệ dự đoán đúng trên tổng số mẫu. Tuy nhiên, trong các tập dữ liệu cảm xúc, nơi số lượng mẫu giữa các lớp thường chênh lệch đáng kể, Accuracy có thể gây hiểu lầm và không phản ánh đúng khả năng phân biệt giữa các cảm xúc.

Ma trận nhầm lẫn (Confusion Matrix) được sử dụng để phân tích chi tiết hành vi của mô hình, cho thấy các lớp cảm xúc nào thường bị nhầm lẫn với nhau. Chẳng hạn, các cảm xúc có mức năng lượng cao như Angry và Happy hoặc các cảm xúc có sắc thái nhẹ như Neutral và Sad thường có tỷ lệ nhầm lẫn cao, phản ánh sự tương đồng về đặc trưng âm học.

Bên cạnh các chỉ số định lượng, phương pháp **đánh giá độc lập theo người nói** đóng vai trò quan trọng. Nhiều công trình trước đây sử dụng phương pháp chia ngẫu nhiên dữ liệu, dẫn đến hiện tượng rò rỉ thông tin khi dữ liệu của cùng một người nói xuất hiện ở cả tập huấn luyện và tập kiểm tra. Để khắc phục vấn đề này, nghiên cứu hiện tại áp dụng chiến lược chia dữ liệu theo Speaker ID, đảm bảo rằng các mẫu trong tập kiểm tra đến từ những người nói hoàn toàn chưa xuất hiện trong quá trình huấn luyện, từ đó nâng cao tính khách quan và khả năng tổng quát hóa của mô hình.

3. Phương pháp luận (Methodology)

3.1 Tập dữ liệu (Datasets)

3.1.1 Xác định nguồn dữ liệu, tính pháp lý, quyền truy cập:

Nguồn dữ liệu chính: Tổng hợp từ 4 dataset trên Kaggle: CREMA-D, SAVEE, TESS, và RAVDESS.


Bộ dữ liệu	Nguồn gốc/Link	Giấy phép
CREMA-D	CREMA-D	ODC-By
SAVEE	SAVEE	Bản quyền thuộc tác giả gốc (© Original Authors)
TESS	TESS	CC BY-NC-ND
RAVDESS	RAVDESS	CC BY-NC-SA

3.1.2 Tự kiểm tra tập dữ liệu gốc trên kaggle

Trong mục này nhóm chúng em sẽ thử tự mình trải nghiệm và đánh giá xem mẫu dữ liệu file ghi âm bản thân mình có đánh giá được đâu là cảm xúc sợ hãi, tức giận , hạnh phúc ...

3.1.2.1 Tập dữ liệu CREMA-D (Crowd-sourced Emotional Multimodal Actors Dataset):

Gồm hơn 7.000 mẫu âm thanh từ 91 diễn viên thuộc nhiều độ tuổi, giới tính và sắc tộc. Đây là bộ dữ liệu có sự đa dạng cao về người nói, giúp mô hình học được nhiều kiểu giọng khác nhau.



Với 6 file ghi âm đầu tiên dài khoảng 2 giây, có chung 1 nội dung là “Don’t forget Jack”, nhóm chúng em có thấy sự khác biệt trong giọng điệu giữa các file, có thể chia làm 2 giọng điệu chính, 1 là giọng điệu nhanh và gấp rút (có thể là cảm xúc tức giận), 2 là giọng điệu chậm và nhẹ nhàng hơn (có thể là cảm xúc vui vẻ, chỉ là lời nhắc nhở). Các file ghi âm còn lại có chú thích cảm xúc trong tên file, tuy nhiên vì thời gian nghe có 2 giây trong 1 file nên 2 cảm xúc rõ nhất là tức giận (Angry) và hạnh phúc (Happy)

3.1.2.2 Tập dữ liệu RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song):

Bao gồm dữ liệu âm thanh và video thu từ 24 diễn viên chuyên nghiệp, thể hiện 8 loại cảm xúc khác nhau. Đây là bộ dữ liệu có chất lượng âm thanh cao, được thu trong môi trường phòng thu ổn định.

 Actor_01	09/12/2025 23:14	File folder
 Actor_02	09/12/2025 23:14	File folder
 Actor_03	09/12/2025 23:14	File folder
 Actor_04	09/12/2025 23:14	File folder
 Actor_05	09/12/2025 23:14	File folder
 Actor_06	09/12/2025 23:14	File folder
 Actor_07	09/12/2025 23:14	File folder
 Actor_08	09/12/2025 23:14	File folder
 Actor_09	09/12/2025 23:14	File folder
 Actor_10	09/12/2025 23:14	File folder
 Actor_11	09/12/2025 23:14	File folder
 Actor_12	09/12/2025 23:14	File folder
 Actor_13	09/12/2025 23:14	File folder
 Actor_14	09/12/2025 23:14	File folder
 Actor_15	09/12/2025 23:14	File folder
 Actor_16	09/12/2025 23:14	File folder
 Actor_17	09/12/2025 23:14	File folder
 Actor_18	09/12/2025 23:14	File folder
 Actor_19	09/12/2025 23:14	File folder
 Actor_20	09/12/2025 23:14	File folder
 Actor_21	09/12/2025 23:14	File folder
 Actor_22	09/12/2025 23:14	File folder
 Actor_23	09/12/2025 23:14	File folder
 Actor_24	09/12/2025 23:14	File folder
 audio_speech_actors_01-24	09/12/2025 23:14	File folder

Tập dữ liệu RAVDESS thì có 24 speaker có độ tuổi, giọng điệu, giới tính khác nhau, cùng nói 1 số nội dung nhất định giống nhau, mỗi file có thời gian nói 3 giây. Có thể phân biệt được khá rõ ràng 2 cảm xúc giống với tập dữ liệu CREMA-D trên, các cảm xúc khác khó phân biệt hơn.

3.1.2.3 Tập dữ liệu SAVEE (Surrey Audio-Visual Expressed Emotion):

Bộ dữ liệu gồm các mẫu âm thanh của 4 nam diễn viên người Anh. Dữ liệu này giúp cân bằng giới tính khi tích hợp với các tập khác.

 AudioData	09/12/2025 23:14	File folder
 DC	09/12/2025 23:14	File folder
 JE	09/12/2025 23:14	File folder
 JK	09/12/2025 23:14	File folder
 KL	09/12/2025 23:14	File folder
 Info.txt	26/10/2019 23:46	Text Document

Tập dữ liệu tuy chỉ nói trong 3 giây nhưng số lượng từ trong 1 câu dài hơn dữ liệu RAVDESS, tuy nhiên các Speaker nói cảm giác giọng tiếng anh Ấn Độ nên khá khó nghe và khó phân biệt được cảm xúc qua file âm thanh.

3.1.2.4 Tập dữ liệu TESS (Toronto Emotional Speech Set):

Tập dữ liệu gồm hơn 2.800 mẫu âm thanh từ hai nữ diễn viên, thể hiện 7 cảm xúc. Đây là bộ dữ liệu chất lượng tốt và tập trung vào giọng nữ.

 OAF_angry	09/12/2025 23:14	File folder
 OAF_disgust	09/12/2025 23:14	File folder
 OAF_Fear	09/12/2025 23:14	File folder
 OAF_happy	09/12/2025 23:14	File folder
 OAF_neutral	09/12/2025 23:14	File folder
 OAF_Pleasant_surprise	09/12/2025 23:14	File folder
 OAF_Sad	09/12/2025 23:14	File folder
 TESS Toronto emotional speech set data	09/12/2025 23:15	File folder
 YAF_angry	09/12/2025 23:15	File folder
 YAF_disgust	09/12/2025 23:15	File folder
 YAF_fear	09/12/2025 23:15	File folder
 YAF_happy	09/12/2025 23:15	File folder
 YAF_neutral	09/12/2025 23:15	File folder
 YAF_pleasant_surprised	09/12/2025 23:15	File folder
 YAF_sad	09/12/2025 23:15	File folder

Tập dữ liệu có 2 giọng nữ , 1 giọng nữ trưởng thành và 1 giọng nữ của trẻ nhỏ. Các file âm thanh có độ dài khá ngắn (1 giây), tuy nhiên vì nội dung khá đơn giản ví dụ như là “Say the word back”, “Say the word bar”,... nên nghe rõ từng từ. Với tập dữ liệu này thì ngoài nghe được rõ cảm xúc tức giận và hạnh phúc, còn có thể cảm giác được cảm xúc buồn (Sad) vì giọng nghe nhẹ nhất.

3.1.2.5 Tổng kết

Khi tự nghe các file âm thanh thì ta đánh giá phụ thuộc vào giọng và âm lượng, có người thì giận, buồn hay vui thì nghe khá là rõ còn vài người thì không nhận ra cảm xúc nào rõ ràng hẳn, và giọng to hơn thì là rõ cảm xúc nhất. Qua cả 4 tập dữ liệu thì âm thanh của cảm xúc tức giận (Angry) rõ ràng nhất

3.1.3 Tích hợp và chuẩn hóa dữ liệu:

Mục tiêu của giai đoạn này là hợp nhất bốn bộ dữ liệu cảm xúc giọng nói (RAVDESS, CREMA-D, TESS, SAVEE) thành một Tập Dữ liệu Tổng hợp duy nhất, có cấu trúc đồng nhất, nhằm tối đa hóa tính đa dạng của người nói và quy mô mẫu cho mô hình.

Sau khi tổng hợp, toàn bộ các tệp âm thanh được ánh xạ về 07 cảm xúc chuẩn trong nghiên cứu: “Angry, Happy, Sad, Fear, Disgust, Surprise, Neutral”, với tổng số mẫu tích hợp thành công là 16498 mẫu và 122 Speaker ID.

Việc tích hợp đa tập dữ liệu (multi-dataset integration) mang lại các lợi ích quan trọng:

- _ Tăng sự đa dạng về giọng nói, giới tính, độ tuổi, vùng miền
- _ Giảm bias mô hình khi huấn luyện chỉ trên một nguồn dữ liệu
- _ Cải thiện khả năng tổng quát hoá do mô hình tiếp xúc nhiều kiểu thu âm và môi trường khác nhau.

3.1.4 Phân bố lớp cảm xúc

Tập dữ liệu bao gồm 7 lớp cảm xúc cơ bản:

Cảm xúc	Số mẫu (xấp xỉ)	Đánh giá
Happy	~2.575	Cân bằng
Sad	~2.575	Cân bằng
Angry	~2.575	Cân bằng
Fear	~2.575	Cân bằng
Disgust	~2.575	Cân bằng
Neutral	~2.319	Gần cân bằng
Surprise	1.304	Mất cân bằng

Lớp Surprise trông chỉ có nửa số mẫu so với các lớp còn lại, thấp hơn đáng kể. Mô hình có xu hướng ưu tiên các lớp xuất hiện nhiều hơn. Recall của lớp Surprise bị suy giảm do mô hình không học đủ biên thể âm học

3.2. Tiền xử lý và trực quan hóa dữ liệu (Preprocessing & Visualization)

Sau khi thu thập và tích hợp dữ liệu âm thanh từ bốn bộ dữ liệu chuẩn gồm CREMA-D, RAVDESS, SAVEE và TESS, toàn bộ dữ liệu được đưa vào giai đoạn tiền xử lý nhằm đảm bảo tính đồng nhất, giảm nhiễu và phù hợp với yêu cầu đầu vào của các mô hình học máy và học sâu. Giai đoạn này khá quan trọng bởi chất lượng của đặc trưng đầu vào ảnh hưởng trực tiếp đến khả năng học và tổng quát hóa của mô hình.


Trước hết, tất cả các tệp âm thanh được đọc trực tiếp từ các thư mục lưu trữ cục bộ. Do các bộ dữ liệu ban đầu được xây dựng trong những bối cảnh khác nhau, tồn tại sự khác biệt đáng kể về tần số lấy mẫu (sampling rate) cũng như độ dài tín hiệu, nghiên cứu tiến hành chuẩn hóa tần số lấy mẫu về 22.050 Hz cho toàn bộ tập dữ liệu. Việc chuẩn hóa này giúp các đặc trưng âm học nằm trên cùng một không gian tần số.

Tiếp theo, các đoạn khoảng lặng ở đầu và cuối mỗi tín hiệu âm thanh được loại bỏ bằng các kỹ thuật phát hiện ngưỡng năng lượng. Bước này giúp mô hình tập trung vào phần nội dung thực sự mang thông tin cảm xúc, đồng thời hạn chế việc học các đặc trưng không liên quan như tiếng hít thở hay nhiễu nền. Sau đó, để đáp ứng yêu cầu về kích thước đầu vào cố định của các mô hình học sâu, tất cả các tệp âm thanh được chuẩn hóa độ dài bằng cách cắt bớt hoặc padding bằng giá trị 0 nhằm đạt cùng một thời lượng xác định. Điều này đặc biệt quan trọng đối với các kiến trúc như CNN và LSTM, vốn không thể xử lý các chuỗi có độ dài thay đổi.


Sau khi hoàn tất tiền xử lý tín hiệu, ta tiến hành trích xuất đặc trưng Mel-spectrogram với 128 dải Mel. Mel-spectrogram biểu diễn sự phân bố năng lượng của tín hiệu âm thanh theo thời gian trên thang tần số Mel – một thang đo gần với cách tai người cảm nhận âm thanh. Để tăng khả năng phân biệt và làm nổi bật các khác biệt về cường độ, Mel-spectrogram được chuyển sang dạng log-scale, giúp giảm sự chênh lệch quá lớn giữa các giá trị biên độ. Đồng thời, ta áp dụng kỹ thuật Sliding Window (Cửa sổ trượt) để chuẩn hóa dữ liệu và tăng cường số lượng mẫu huấn luyện, lên tới **46315 mẫu**.

Để trực quan hóa và phân tích định tính dữ liệu, các hình minh họa Mel-spectrogram của một số mẫu âm thanh đại diện cho các cảm xúc Happy, Sad, Angry, Fear và Disgust.


Qua quan sát ta thấy rằng cảm xúc Angry thường thể hiện năng lượng mạnh, dải tần rộng và biên độ cao




trong khi đó Sad có xu hướng tập trung năng lượng ở các dải tần thấp hơn với cường độ nhỏ và nhịp điệu chậm.




Cảm xúc Happy nằm giữa hai thái cực này, với năng lượng tương đối cao nhưng phân bố đều và ổn định hơn.



Với Fear, ta có thể quan sát thấy năng lượng thấp hơn so với các cảm xúc kích thích cao, phân bố không liên tục và xen kẽ nhiều khoảng lặng. Năng lượng chủ yếu tập trung ở các dải tần thấp, phản ánh giọng nói run, yếu và thiếu ổn định.



Cuối cùng với Disgust, phổ năng lượng cho thấy sự phân bố không đồng đều theo thời gian, với các đoạn năng lượng tăng giảm đột ngột và tập trung chủ yếu ở các dải tần trung bình-thấp. Kiểu phân bố này phản ánh đặc trưng phát âm ngắt quãng, âm sắc gằn và cường độ không ổn định.



Nhìn chung, các bước tiền xử lý và trực quan hóa cho thấy dữ liệu sau khi xử lý đã đạt được tính nhất quán cao, giảm nhiều không cần thiết và sẵn sàng cho giai đoạn huấn luyện mô hình.

3.3 Huấn luyện mô hình

Chia tập dữ liệu: 80% Train - 20% Test (chia theo danh sách người nói, không chia ngẫu nhiên mẫu).

Chuẩn hóa: Z-score Normalization toàn cục dựa trên thống kê của tập Train.

Trong nghiên cứu này, nhiều mô hình khác nhau được huấn luyện nhằm so sánh hiệu quả nhận diện cảm xúc từ giọng nói, bao gồm cả mô hình truyền thống và mô hình học sâu.

CNN 2D được huấn luyện để học các đặc trưng không gian cục bộ trên Mel-spectrogram, chẳng hạn như các dải năng lượng và formant.

LSTM được áp dụng trên chuỗi Mel theo trục thời gian, cho phép mô hình học được các đặc trưng động như nhịp điệu và sự biến thiên cảm xúc theo thời gian.

CNN-LSTM là mô hình lai, trong đó CNN đóng vai trò trích xuất đặc trưng cục bộ, sau đó LSTM khai thác thông tin chuỗi, giúp kết hợp ưu điểm của cả hai kiến trúc.


Quá trình huấn luyện sử dụng Adam optimizer và hàm mất mát Categorical Crossentropy. Kỹ thuật Early Stopping được áp dụng để tránh hiện tượng overfitting, đồng thời mô hình tốt nhất được lưu lại thông qua Model Checkpoint.

Việc chia dữ liệu được thực hiện theo speaker-wise split, đảm bảo rằng giọng nói của một người không xuất hiện đồng thời trong cả tập huấn luyện và tập kiểm tra, từ đó nâng cao độ tin cậy của kết quả đánh giá.

3.3 Phân tích kết quả và đánh giá

3.3.1 Phân tích chi tiết từng mô hình

--- BẢNG XẾP HẠNG ---		
	Model	Accuracy
0	CNN-2D	0.521047
2	CNN-LSTM	0.458731
1	LSTM	0.456983



CNN 2D

CNN 2D là mô hình đạt hiệu năng cao nhất trong nghiên cứu, chứng minh hiệu quả của việc sử dụng Mel-spectrogram như một biểu diễn dạng ảnh. Các lớp tích chập cho phép mô hình học được các đặc trưng cục bộ theo cả trục tần số và thời gian, từ đó nâng cao khả năng nhận diện các mẫu cảm xúc đặc trưng.


LSTM

Mô hình LSTM tập trung vào việc học các phụ thuộc theo chuỗi thời gian của tín hiệu âm thanh. Kết quả cho thấy LSTM hoạt động tốt trong việc phân tích nhịp điệu và sự biến thiên cảm xúc theo thời gian. Tuy nhiên, do thiếu cơ chế trích xuất đặc trưng không gian cục bộ, hiệu năng của LSTM là thấp nhất trong cả 3 mô hình.

CNN-LSTM (Hybrid Model)

CNN-LSTM cho kết quả cải thiện rõ rệt so với các mô hình trước. Conv1D sẽ quét các ảnh phổ để xác định chính xác những chuỗi đặc trưng rồi chuyển sang LSTM để tránh gây nhiễu và LSTM sẽ khai thác tính chuỗi, giúp mô hình học được cả đặc trưng cục bộ và động học của cảm xúc. Tuy nhiên, độ chính xác của CNN-LSTM còn kém so với CNN thuần sử dụng Conv2D, do Conv1D chỉ quét ảnh phổ theo 1 chiều chuỗi thời gian còn Conv2D đã quét cả chiều ngang và dọc của ảnh phổ.

3.3.2 Phân tích ma trận nhầm lẫn



Ma trận nhầm lẫn cho thấy một số cặp cảm xúc thường xuyên bị nhầm lẫn, bao gồm Neutral–Sad, Fear–Surprise và Angry–Disgust. Hiện tượng này có thể được


lý giải bởi sự tương đồng về cường độ năng lượng, cao độ và nhịp điệu trong tín hiệu âm thanh của các cảm xúc này.

Mô hình CNN-LSTM thể hiện khả năng giảm đáng kể tỷ lệ nhầm lẫn so với các mô hình khác, đặc biệt đối với các lớp có số lượng mẫu ít, cho thấy khả năng khái quát hóa tốt hơn.

3.3.3 Phân tích nguyên nhân gốc rễ của sai lệch dự đoán và giới hạn mô hình

Dựa trên kết quả thực nghiệm từ các biểu đồ huấn luyện và ma trận nhầm lẫn, có ba nhóm nguyên nhân chính dẫn đến sự sụt giảm hiệu suất và sai lệch trong việc nhận dạng cảm xúc:

3.3.3.1 Hiện tượng Quá khớp (Overfitting) nghiêm trọng



Quan sát trực quan từ biểu đồ đường cong huấn luyện (Loss/Accuracy theo Epochs), ta nhận thấy một sự đứt gãy lớn trong khả năng tổng quát hóa của mô hình:

Sự phân kỳ của các chỉ số: Trong khi độ chính xác trên tập huấn luyện (Train Accuracy) tiệm cận mức 90%, độ chính xác trên tập kiểm tra (Validation Accuracy) chỉ dừng lại ở mức trung bình khoảng 52%.

Xu hướng của hàm mất mát (Loss function): Đường *Validation Loss* bắt đầu có xu hướng tăng mạnh và dao động sau **Epoch thứ 5**, trong khi *Train Loss* vẫn liên tục giảm sâu xuống dưới 0.5.

Nguyên nhân kỹ thuật: Mô hình CNN đã thay vì học các đặc trưng cảm xúc trừu tượng, nó lại chuyển sang "học thuộc lòng" các đặc tính nhiễu hoặc các đặc điểm sinh học cụ thể của từng diễn viên và điều kiện môi trường thu âm đặc thù của từng bộ dữ liệu. Điều này lý giải tại sao mô hình đạt kết quả cực cao trên dữ liệu đã biết nhưng lại thất bại khi đối mặt với những giọng nói mới trong tập kiểm tra.

3.3.3.2 Giới hạn nội tại của phương pháp Mel-Spectrogram kết hợp CNN

Mặc dù CNN 2D đạt hiệu suất cao nhất (**52.1%**) so với các kiến trúc khác như LSTM hay MLP, sự kết hợp này vẫn tồn tại những rào cản về mặt bản chất xử lý thông tin:

Mất mát thông tin ngữ cảnh thời gian dài: CNN hoạt động bằng cách trích xuất các đặc trưng cục bộ trên hình ảnh phổ (spatial patterns). Tuy nhiên, cảm xúc giọng nói thường phụ thuộc vào sự biến thiên cao độ và nhịp điệu trên toàn bộ câu nói. Việc chỉ "nhìn" vào các khung hình Mel-Spectrogram tĩnh khiến mô hình bỏ lỡ các yếu tố phi ngôn ngữ quan trọng. Thêm nữa, mô hình hoàn toàn không hiểu nội dung văn bản (ngữ nghĩa). Trong thực tế, cùng một dạng sóng âm thanh nhưng ý nghĩa từ ngữ có thể thay đổi hoàn toàn cảm xúc (như các trường hợp mỉa mai, châm biếm hoặc nói lầy). Do đó, khi không có sự hỗ trợ từ các mô hình ngôn ngữ, CNN thuần túy khó lòng phân biệt được các sắc thái cảm xúc ẩn ý.

3.3.3.3 Sự không đồng nhất và mất cân bằng trong dữ liệu đa nguồn

Việc tích hợp từ 4 nguồn (RAVDESS, CREMA-D, TESS, SAVEE) mang lại sự đa dạng nhưng cũng tạo ra thách thức lớn về **Domain Mismatch**:

Ma trận nhầm lẫn (Confusion Matrix) chỉ ra rằng mô hình thường xuyên nhầm lẫn giữa *Fear* và *Neutral* (336 mẫu bị đoán sai). Điều này bắt nguồn từ việc ở một số bộ dữ liệu, diễn viên diễn đạt sự sợ hãi ở cường độ thấp, khiến đặc trưng phổ gần như tương đồng với trạng thái trung tính. Biểu đồ phân bố cho thấy lớp *Surprise* có số lượng mẫu thấp nhất (khoảng 1300 mẫu) so với các lớp khác (trên 2500 mẫu). Sự thiếu hụt dữ liệu huấn luyện cho các lớp đặc thù như *Surprise* khiến mô hình không đủ kinh nghiệm để nhận diện chính xác lớp này. Thêm nữa, mỗi bộ dữ liệu có một tiêu chuẩn diễn xuất khác nhau (kịch tính hóa

ở RAVDESS hoặc tự nhiên hơn ở CREMA-D). Sự không đồng nhất này khiến mô hình khó tìm được một "vùng đặc trưng chung" cho từng loại cảm xúc trên tất cả các nguồn dữ liệu.

4. Một số kịch bản nhóm triển khai thêm và kết quả thực nghiệm

Để giải quyết vấn đề chồng chéo đặc trưng giữa các cảm xúc và nâng cao độ chính xác của hệ thống, nhóm đã tiến hành thực nghiệm theo lộ trình từ xử lý dữ liệu thô đến việc tinh chỉnh không gian nhãn (Label Merging). Các quyết định gộp nhãn được đưa ra dựa trên phân tích Ma trận nhầm lẫn (Confusion Matrix) của kịch bản liên trước.

Dưới đây là chi tiết từng kịch bản và kết quả đạt được trên tập kiểm thử (Test Set) sử dụng mô hình CNN-2D.

4.1. Kịch bản cơ sở: Sử dụng Sliding Window (7 nhãn)

Nhóm áp dụng kỹ thuật **Sliding Window** (cửa sổ 1 giây, bước trượt 0.5 giây) để tăng cường dữ liệu.

Cấu hình: 7 nhãn gốc (Angry, Happy, Sad, Fear, Disgust, Surprise, Neutral).

Kết quả: Độ chính xác tổng thể đạt **53.09%**.

Vấn đề: Có sự nhầm lẫn lớn giữa các cặp nhãn có cùng mức năng lượng (Arousal) hoặc độ tích cực (Valence), đặc biệt là giữa Sad (Buồn) và Neutral (Trung tính).


4.2. Kịch bản gộp nhãn Sad - Neutral

Để khắc phục sự nhập nhằng ở vùng năng lượng thấp, nhóm tiến hành gộp **Sad** vào **Neutral**.

Cấu hình: 6 nhãn (Angry, Happy, Fear, Disgust, Surprise, **Neutral**).

Kết quả: Độ chính xác tăng lên **58.21%**.

Phân tích Ma trận nhầm lẫn :



Lớp Surprise (Ngạc nhiên): Đạt độ chính xác rất cao với **4761** mẫu dự đoán đúng. Tuy nhiên, một phần nhỏ bị nhầm sang Fear (507 mẫu) do tính chất bất ngờ của cả hai.

Lớp Disgust: Mô hình gặp khó khăn lớn trong việc nhận diện Disgust hề . Có tới **1360** mẫu thực tế là Disgust nhưng lại bị dự đoán nhầm thành Neutral, cao hơn cả số mẫu dự đoán đúng (611). Điều này cho thấy đặc trưng phổ của Disgust trong tập dữ liệu này khá mờ nhạt và dễ bị lẫn vào các khoảng lặng hoặc giọng nói bình thường.


4.3. Kịch bản gộp nhãn Sad - Neutral và Fear - Surprise

Dựa trên quan sát ở kịch bản 4.2 về sự nhầm lẫn giữa Fear và Surprise, nhóm tiếp tục gộp **Surprise** vào **Fear** (gom nhóm High Arousal).

Cấu hình: 5 nhãn (Angry, Happy, Disgust, **Fear**, Neutral).

Kết quả: Độ chính xác đạt **59.61%**.

Phân tích Ma trận nhầm lẫn :



Lớp Fear : Sau khi gộp Surprise, số lượng mẫu dự đoán đúng của Fear là **2989**, cho thấy sự ổn định của nhóm nhãn năng lượng cao.

Lớp Neutral: Duy trì độ chính xác cực tốt với **4849** mẫu đúng.

Sự dịch chuyển của nhiều (Lớp Disgust): Ở kịch bản trước, Disgust bị nhầm thành Neutral. Tuy nhiên ở kịch bản này, Disgust lại bị dự đoán nhầm sang **Fear** một cách nghiêm trọng (**1557** mẫu nhầm lẫn so với chỉ 627 mẫu đúng). Điều này củng cố giả thuyết rằng Disgust là một cảm xúc phức tạp, mang đặc điểm gần giọng (giống Angry) và căng thẳng (giống Fear), nên cần được gộp vào nhóm tiêu cực mạnh.


4.4. Kịch bản gộp nhãn: Sad-Neutral, Fear-Surprise, Angry-Disgust

Để giải quyết triệt để sự mất ổn định của nhãn Disgust, nhóm quyết định gộp **Disgust** vào **Angry** để tạo thành nhóm cảm xúc "Tiêu cực/Hung hăng".

Cấu hình: 4 nhãn (**Angry**, Happy, Fear, Neutral).

Kết quả: Độ chính xác tăng mạnh lên **67.94%**.

Phân tích Ma trận nhầm lẫn :



Lớp Angry (Giận dữ): Việc gộp Disgust đã phát huy tác dụng rõ rệt. Số mẫu dự đoán đúng của Angry đạt **3879**, trở thành một trong những lớp nhận diện tốt nhất.

Lớp Neutral: Vẫn giữ phong độ cao với **4876** mẫu đúng.

Điểm yếu còn lại (Lớp Happy): Lớp Happy (Vui vẻ) trở thành mắt xích yếu nhất. Có **1937** mẫu đúng, nhưng bị phân tán đáng kể sang Neutral (480 mẫu) và Angry (463 mẫu). Lý do là vì Happy có biên độ dao động lớn, các đoạn cười lớn dễ nhầm với Angry, trong khi các đoạn nói chuyện vui vẻ nhẹ nhàng lại giống Neutral.


4.5. Kịch bản tối ưu: Bỏ Happy

Nhận thấy Happy làm giảm hiệu suất trung bình và thường xuyên gây nhiễu, nhóm thực hiện kịch bản cuối cùng là loại bỏ nhãn Happy, tập trung vào bài toán cảnh báo tiêu cực (Angry, Fear) và trạng thái bình thường (Neutral).

Cấu hình: 3 nhãn (Angry, Fear, Neutral).

Kết quả: Hệ thống đạt hiệu suất cao nhất với **83.25%**.

Phân tích Ma trận nhầm lẫn : Đây là kết quả tối ưu nhất của đề án, thể hiện qua ma trận:



Đường chéo chính rõ nét: Cả 3 lớp đều có tỷ lệ nhận diện đúng vượt trội:

Angry: 2095 mẫu đúng.

Fear: 2623 mẫu đúng.

Neutral: 2550 mẫu đúng.

Sự phân tách rõ ràng:

Sự nhầm lẫn giữa **Neutral** và **Angry** rất thấp (chỉ 86 mẫu thực tế Neutral bị đoán là Angry), cho thấy mô hình hiếm khi báo động giả (False Positive) về sự giận dữ khi người dùng đang bình tĩnh.

Sự nhầm lẫn chủ yếu nằm ở cặp **Angry - Fear** (503 mẫu Angry bị đoán là Fear), điều này có thể chấp nhận được vì cả hai đều là cảm xúc tiêu cực cần cảnh báo.

4.6. Tổng hợp kết quả

Bảng dưới đây tóm tắt quá trình cải thiện độ chính xác của mô hình **CNN-2D** qua từng bước tinh chỉnh dữ liệu:

Kịch bản	Không gian nhãn	Accuracy (CNN-2D)	Phân tích quan trọng từ Confusion Matrix
4.1	7 Nhãn gốc	53.09%	Nhầm lẫn cao giữa Sad ↔ Neutral.
4.2	6 Nhãn (Gộp Sad → Neutral)	58.21%	Disgust bị nhầm lẫn nghiêm trọng sang Neutral (1360 mẫu).
4.3	5 Nhãn (Gộp thêm Surprise → Fear)	59.61%	Disgust chuyển sang bị nhầm lẫn với Fear (1557 mẫu).
4.4	4 Nhãn (Gộp thêm Disgust → Angry)	67.94%	Angry cải thiện mạnh (3879 mẫu đúng). Happy là lớp yếu nhất.

4.5 3 Nhãn (Bỏ Happy) **83.25%** Các lớp phân tách rõ rệt. Tỷ lệ
báo động giả thấp.

Kết luận: Chiến lược gộp nhãn dựa trên phân tích Confusion Matrix đã chứng minh tính hiệu quả. Từ độ chính xác khởi điểm ~53%, nhóm đã nâng cao hiệu suất lên ~83% bằng cách xây dựng không gian nhãn phù hợp với đặc trưng âm học và loại bỏ các dữ liệu gây nhiễu.

5. Kết luận và Hướng phát triển (Conclusion & Future Work)

5.1 Kết luận

Nghiên cứu đã đề xuất một quy trình nhận diện cảm xúc từ giọng nói dựa trên việc tích hợp đa bộ dữ liệu và so sánh nhiều mô hình học máy và học sâu. Kết quả thực nghiệm cho thấy việc sử dụng Mel-spectrogram kết hợp với các mô hình học sâu, đặc biệt là kiến trúc CNN-LSTM, mang lại hiệu quả vượt trội so với các phương pháp truyền thống.

Các thí nghiệm cũng khẳng định tầm quan trọng của việc chia dữ liệu theo speaker nhằm tránh hiện tượng rò rỉ thông tin và đảm bảo tính khách quan của kết quả đánh giá.

5.2 Hướng phát triển

Trong tương lai, nghiên cứu có thể được mở rộng theo các hướng sau:

- _ Áp dụng các kiến trúc học sâu tiên tiến như Transformer, Conformer hoặc Temporal Convolutional Network cho bài toán nhận diện cảm xúc từ giọng nói.
- _ Kết hợp thêm thông tin ngữ nghĩa thông qua việc tích hợp mô-đun nhận dạng tiếng nói tự động để xây dựng hệ thống đa phương thức.
- _ Nghiên cứu các kỹ thuật cân bằng dữ liệu và tăng cường dữ liệu nhằm cải thiện hiệu năng đối với các cảm xúc hiếm.

_ Triển khai hệ thống nhận diện cảm xúc trong môi trường thời gian thực, phục vụ các ứng dụng thực tế như trợ lý ảo, phân tích hành vi khách hàng hoặc chăm sóc sức khỏe tâm lý.

Tài liệu tham khảo

- [1] D. Ververidis and C. Kotropoulos, “Emotional speech recognition: Resources, features, and methods,” *Speech Communication*, vol. 48, no. 9, pp. 1162–1181, 2006, doi: 10.1016/j.specom.2006.04.003.
- [2] B. Schuller, S. Steidl, and A. Batliner, “The INTERSPEECH 2009 Emotion Challenge,” in *Proceedings of Interspeech*, Brighton, UK, 2009, pp. 312–315.
- [3] S. Davis and P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 28, no. 4, pp. 357–366, 1980, doi: 10.1109/TASSP.1980.1163420.
- [4] T. L. Nwe, S. W. Foo, and L. C. De Silva, “Speech emotion recognition using hidden Markov models,” *Speech Communication*, vol. 41, no. 4, pp. 603–623, 2003, doi: 10.1016/S0167-6393(03)00099-2.
- [5] Y. Lecun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.
- [6] K. Han, D. Yu, and I. Tashev, “Speech emotion recognition using deep neural network and extreme learning machine,” in *Proceedings of Interspeech*, Singapore, 2014, pp. 223–227.

- [7] A. Graves, A. Mohamed, and G. Hinton, “Speech recognition with deep recurrent neural networks,” in *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Vancouver, Canada, 2013, pp. 6645–6649, doi: 10.1109/ICASSP.2013.6638947.
- [8] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [9] Z. Huang, M. Dong, Q. Mao, and Y. Zhan, “Speech emotion recognition using CNN,” in *Proceedings of the ACM International Conference on Multimedia*, Amsterdam, Netherlands, 2014, pp. 801–804, doi: 10.1145/2647868.2654899.
- [10] Y. Zhang, J. Du, Z. Wang, and Y. Tu, “Speech emotion recognition using deep convolutional neural network and discriminant temporal pyramid matching,” *IEEE Transactions on Multimedia*, vol. 20, no. 6, pp. 1576–1590, 2018, doi: 10.1109/TMM.2017.2766843.
- [11] S. Poria, E. Cambria, G. Hazarika, and N. Howard, “Multimodal sentiment analysis: Addressing key issues and setting up baselines,” *IEEE Intelligent Systems*, vol. 33, no. 6, pp. 17–25, 2018, doi: 10.1109/MIS.2018.2882362.
- [12] B. Schuller, A. Batliner, S. Steidl, and D. Seppi, “Recognising realistic emotions and affect in speech: State of the art and lessons learnt from the first challenge,” *Speech Communication*, vol. 53, no. 9–10, pp. 1062–1087, 2011, doi: 10.1016/j.specom.2011.01.011.
- [13] F. Eyben, M. Wöllmer, and B. Schuller, “OpenSMILE – The Munich versatile and fast open-source audio feature extractor,” in *Proceedings of the ACM International Conference on Multimedia*, Florence, Italy, 2010, pp. 1459–1462, doi: 10.1145/1873951.1874246.

[14] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.